

بحث تكميلي ضمن متطلبات درجة الماجستير

نظام ذكي لفحص جودة العلب البلاستيكية على خطوط الإنتاج باستخدام الرؤية الحاسوبية والذكاء الاصطناعي التوليدي

دراسة تطبيقية شاملة: التصميم، المعمارية، آلية عمل الذكاء الاصطناعي،
والنتائج

اسم النظام: Bottle Defect Detector (كاشف عيوب العلب)

نموذج الذكاء الاصطناعي المستخدم: Anthropic Claude Sonnet 5 (رؤية

حاسوبية متعددة الوسائط)

لغة التطوير: Python 3.10+

نوع الفصل: فصل تطبيقي/منهجي ضمن رسالة الماجستير — الجانب العملي

والتقني للمشروع

أنظمة صناعية
ذكية

فحص جودة
آلي

تعلم بالأمثلة
القليلة

رؤية
حاسوبية

فهرس المحتويات

الفصل الأول: المقدمة والإطار العام للمشروع

- 1.1 مقدمة عامة
- 1.2 مشكلة البحث
- 1.3 أهمية الموضوع
- 1.4 أهداف المشروع
- 1.5 حدود ونطاق المشروع

الفصل الثاني: الإطار النظري والتقنيات المعتمدة

- 2.1 الفحص البصري الآلي لجودة المنتجات
- 2.2 من الرؤية الحاسوبية التقليدية إلى النماذج التوليدية متعددة الوسائط
- 2.3 نماذج الرؤية اللغوية ونموذج Claude
- 2.4 التعلم بالأمثلة القليلة (Few-shot Learning) كبديل عن إعادة التدريب
- 2.5 خوارزميات تتبع الكائنات عبر الإطارات المتعاقبة
- 2.6 معالجة الصور في فضاء الألوان HSV

الفصل الثالث: منهجية ومراحل بناء المشروع

- 3.1 مرحلة التخطيط وتحديد المتطلبات
- 3.2 مرحلة تطوير وحدة الكشف عن العلب
- 3.3 مرحلة تطوير وحدة التتبع
- 3.4 مرحلة دمج الذكاء الاصطناعي التوليدي
- 3.5 مرحلة التحقق وتطبيع المخرجات
- 3.6 مرحلة التصدير والتقارير
- 3.7 مرحلة بناء الواجهة الرسومية
- 3.8 مرحلة التغليف والتوزيع

الفصل الرابع: المعمارية التفصيلية للنظام

الفصل الخامس: آلية عمل الذكاء الاصطناعي وتصنيف العيوب

الفصل السادس: التحديات التقنية الفعلية وحلولها

الفصل السابع: واجهات الاستخدام (سطر الأوامر والواجهة الرسومية)

الفصل الثامن: النتائج والتقارير المصدرة

الفصل التاسع: مميزات النظام من الألف إلى الياء

الفصل العاشر: حدود النظام والتوصيات المستقبلية

الخاتمة

المراجع

المقدمة والإطار العام للمشروع

1.1 مقدمة عامة

يشهد قطاع الصناعات التحويلية، وعلى رأسها صناعة التعبئة والتغليف بالعبوات البلاستيكية، تحولاً جوهرياً في أساليب مراقبة الجودة، حيث بدأت المصانع بالتخلي التدريجي عن أساليب الفحص البصري اليدوي التقليدي التي يقوم بها عامل مختص يراقب العلب أثناء مرورها على السير الناقل، والاتجاه نحو حلول الفحص الآلي القائمة على الرؤية الحاسوبية والذكاء الاصطناعي. يعود هذا التحول إلى محدودية القدرة البشرية على الحفاظ على مستوى ثابت من الانتباه والدقة لساعات طويلة متواصلة، إضافة إلى الكلفة التشغيلية المرتفعة لتوظيف عدد كافٍ من المفتشين لتغطية خطوط الإنتاج المتعددة على مدار الوردية الواحدة.

يقدم هذا الفصل عرضاً تطبيقياً شاملاً لمشروع برمجي متكامل يحمل اسم "كاشف عيوب العلب" (Bottle Defect Detector)، صُمم ليحل محل محطة فحص آلية بديلة أو مساعدة للعامل البشري، تراقب سيراً ناقلاً عبر كاميرا حية أو عبر ملف فيديو مسجل، وتكتشف العيوب البلاستيكية البيضاء تلقائياً بالاعتماد على تقنيات معالجة الصور التقليدية، ثم تلتقط صورة واضحة ومقصوفة (Crop) لكل علة على حدة، وترسل هذه الصورة إلى نموذج ذكاء اصطناعي توليدي متعدد الوسائط (نموذج Claude من شركة Anthropic) لتحليلها بصرياً وتحديد ما إذا كانت سليمة أو تحتوي على عيب من عيوب الجودة المعروفة، قبل أن تُصدر النتائج بشكل منظم في ملف JSON وتقرير Excel احترافي يتضمن الصور المصغرة لكل علة وتحليلها جنباً إلى جنب.

1.2 مشكلة البحث

تتمثل المشكلة البحثية التي ينطلق منها هذا المشروع في التساؤل التالي: هل يمكن الاستغناء عن نماذج الرؤية الحاسوبية التقليدية المتخصصة (والتي تتطلب عادة جمع آلاف الصور المصنّفة يدوياً وتدريب نموذج تصنيف مخصص من الصفر) في مهام فحص الجودة الصناعية محدودة النطاق، والاستعاضة عنها بنموذج ذكاء اصطناعي توليدي عام الغرض (General-Purpose Multimodal LLM) لم يُدرَّب أصلاً على بيانات هذا الخط الصناعي بعينه؟ وإذا كان ذلك ممكناً، فما هي الآلية التقنية التي تجعل نموذجاً عاماً كهذا قادراً على تمييز عيوب بصرية دقيقة وأحياناً خفية جداً على منتج صناعي واحد بعينه، رغم أنه لم يخضع لأي عملية تدريب أو ضبط دقيق (Fine-tuning) خاصة بهذا المنتج؟

يضاف إلى ذلك إشكالية فرعية بالغة الأهمية تتعلق بمصادقية النتائج: بما أن هذا النوع من الأنظمة لا يعتمد على نموذج مُدرَّب إحصائياً بالمعنى التقليدي (لا توجد بيانات تدريب ولا بيانات اختبار منفصلة بالمفهوم الكلاسيكي لتعلم الآلة)، فكيف يمكن قياس أداء النظام والتعبير عن موثوقيته رقمياً بشكل لا يوهم الباحث أو متخذ القرار الصناعي بدقة إحصائية غير موجودة فعلياً؟ وقد تعامل هذا المشروع مع هذه الإشكالية بصراحة منهجية تامة، كما سيوضح الفصل الخامس.

1.3 أهمية الموضوع

تتبع أهمية هذا الموضوع من عدة زوايا مترابطة. فمن الناحية الصناعية العملية، يقدم النظام حلاً منخفض الكلفة نسبياً مقارنة بأنظمة الفحص الآلي المتخصصة (Machine Vision Systems) التقليدية التي تتطلب استثماراً كبيراً في عتاد مخصص وبرمجيات مغلقة المصدر وخبرات هندسية متعمقة في معالجة الصور الصناعية. فمن الناحية العلمية والبحثية، يمثل المشروع دراسة حالة (Case Study) واقعية وموثقة بالتفصيل حول كيفية توظيف نماذج اللغة والرؤية الكبيرة (Large Vision-Language Models) في سياق تطبيقي صناعي ضيق النطاق ومحدد جداً، وهو سياق يختلف جوهرياً عن الاستخدامات الشائعة لهذه النماذج في المحادثة العامة أو توليد النصوص. كما يبرهن المشروع عملياً على مفهوم مهم في أدبيات الذكاء الاصطناعي الحديثة، وهو أن التعلم بالأمثلة القليلة (Few-shot Learning) عبر إرفاق صور مرجعية حقيقية مع كل استعلام يمكن أن يحل محل عملية إعادة التدريب المكلفة، بشرط اختيار الأمثلة المرجعية بعناية ومراقبة أدائها ميدانياً

وتحسينها تكرارياً — وهي بالضبط المنهجية التي أثبتت في تطوير هذا النظام والموثقة بالتفصيل في الفصل السادس.

1.4 أهداف المشروع

- تصميم وتطوير نظام متكامل قادر على رصد اللعب البلاستيكية آلياً من مصدر فيديو حي (كاميرا) أو مسجل (ملف فيديو)، دون الحاجة لأي تدخل بشري في مرحلة الكشف الأولي.
- بناء آلية تتبع (Tracking) موثوقة تضمن التقاط صورة واحدة فقط لكل علبة فعلية أثناء مرورها، وتفاذي التقاط صور مكررة لنفس العلبة أو صور جزئية للعلب الداخلية أو الخارجية من إطار الكاميرا.
- دمج نموذج ذكاء اصطناعي توليدي متعدد الوسائط (Claude Sonnet 5) كمحرك تحليل بصري رئيسي، مع تصميم أوامر نصية (Prompts) هندسية دقيقة تُترجم متطلبات الفحص الصناعي إلى تعليمات مفهومة للنموذج.
- تطوير آلية تعلم بالأمثلة المرجعية (Few-shot Reference Images) تُغني عن الحاجة لتدريب نموذج رؤية حاسوبية مخصص من الصفر، وتسمح بتحسين أداء الكشف تكرارياً بمجرد استبدال أو إضافة صور مرجعية دون أي تعديل برمجي.
- تصنيف العيوب المكتشفة ضمن فئات واضحة ومحددة (عيب في الجسم، اتساح، عيب تصنيعي جسيم) بما يعكس واقع خط الإنتاج الفعلي المدروس.
- إخراج تقارير منظمة وقابلة للتدقيق البشري بصيغتي JSON و Excel، تتضمن الصور الفعلية لكل علبة إلى جانب تحليلها النصي ومؤشرات ثقة رقمية.
- توفير واجهتي استخدام مختلفتين: واجهة سطر أوامر (CLI) موجهة للتشغيل التقني والاختبار، وواجهة رسومية (GUI) سهلة الاستخدام موجهة للمشغل الميداني غير التقني.

1.5 حدود ونطاق المشروع

يقتصر نطاق هذا المشروع على فحص نوع واحد محدد من العلب البلاستيكية البيضاء (عبوات واسعة الفوهة بدون غطاء)، ولا يغطي بشكل مباشر أنواعاً أخرى من العبوات ذات الألوان أو الأشكال المختلفة إلا بعد إعادة معايرة عتبات الكشف اللونية وتزويد النظام بصور مرجعية جديدة تلأئم المنتج الجديد. كما أن النظام مصمم أصلاً لخطوط إنتاج لا تركّب فيها الأغشية على العلب في هذه المرحلة من خط التصنيع، وبالتالي لا يتضمن فحص عيوب الغطاء ضمن نطاقه الحالي. أخيراً، فإن مؤشرات الدقة والاسترجاع والضبط الواردة في تقارير النظام هي مؤشرات مشتقة من ثقة النموذج الذاتية بقراره، وليست مقاييس إحصائية حقيقية بالمعنى الكلاسيكي لعلم تعلم الآلة، نظراً لغياب خطوة فحص بشري مرجعي (Ground Truth) مستقلة تتم مقارنة نتائج النظام معها — وهي نقطة يوضحها هذا الفصل بالتفصيل الكامل في الفصل الخامس والفصل العاشر.

الإطار النظري والتقنيات المعتمدة

2.1 الفحص البصري الآلي لجودة المنتجات

يُعرّف الفحص البصري الآلي لجودة المنتجات (Automated Visual Inspection) بأنه مجموعة الأساليب التقنية التي تستبدل عين المفتش البشري بمستشعر بصري (كاميرا) مقترن بخوارزمية تحليل، بهدف الكشف عن الانحرافات البصرية عن المواصفة القياسية للمنتج السليم. تقليدياً، اعتمدت هذه الأنظمة على تقنيات معالجة الصور الكلاسيكية مثل عتبات الشدة اللونية (Thresholding)، وكشف الحواف (Edge Detection)، ومطابقة القوالب (Template Matching)، وهي أساليب فعالة في حالات محددة جيداً ومنضبطة الإضاءة لكنها تعاني من هشاشة كبيرة أمام أي تغير طفيف في زاوية التصوير أو الإضاءة أو شكل العيب. لاحقاً، ظهرت أنظمة قائمة على الشبكات العصبية الالتفافية (Convolutional Neural Networks) المدربة خصيصاً على مجموعات بيانات كبيرة من صور المنتج السليم والمعيّب، وهي أكثر مرونة لكنها تتطلب استثماراً كبيراً في جمع البيانات وتصنيفها يدوياً وإعادة التدريب كلما تغيرت طبيعة العيوب المستهدفة.

2.2 من الرؤية الحاسوبية التقليدية إلى النماذج التوليدية متعددة

الوسائط

شهدت السنوات الأخيرة ظهور فئة جديدة من النماذج تُعرف بنماذج الرؤية اللغوية الكبيرة (Large Vision-Language Models)، وهي نماذج مدربة مسبقاً (Pre-trained) على كميات هائلة ومتنوعة من الصور والنصوص المقترنة، مما يمنحها قدرة عامة على "فهم" محتوى الصور ووصفه والاستدلال عليه بلغة طبيعية، دون الحاجة لتدريب مخصص على كل مهمة جديدة. يعتمد هذا المشروع على هذه الفئة تحديداً، إذ يوظف نموذج Claude Sonnet 5

من شركة Anthropic كمحرك تحليل بصري وحيد، ويرسل له صورة كل علبة مقترنة بأوامر نصية دقيقة تحدد المطلوب بوضوح تام، بدلاً من الاعتماد على نموذج تصنيف مدّرب خصيصاً.

2.3 نماذج الرؤية اللغوية ونموذج Claude

تقبل نماذج الرؤية اللغوية الحديثة، ومنها عائلة نماذج Claude، مدخلات مختلطة من الصور والنصوص ضمن محادثة واحدة (Multimodal Message)، وتُخرج استجابة نصية تصف أو تحلل أو تستدل على محتوى تلك الصور بناءً على التعليمات النصية المرفقة. في سياق هذا المشروع، تُرسل كل صورة علبة مقصوصة (Crop) إلى النموذج مُرمّزة بصيغة Base64 ضمن رسالة تحتوي أيضاً على أمر نظام (System Prompt) يحدد هوية النموذج كخبير فحص جودة، وأمر مستخدم (User Prompt) يطلب إخراج نتيجة التحليل بصيغة JSON مضغوطة ومحددة البنية بدقة، بهدف تقليل عدد الرموز اللغوية المُستهلكة في المخرجات (Output Tokens) وضمان سهولة التحقق الآلي من صحة بنية الاستجابة.

2.4 التعلم بالأمثلة القليلة كبدل عن إعادة التدريب

يمثل مفهوم التعلم بالأمثلة القليلة (Few-shot Learning / In-context Learning) حجر الزاوية التقني الذي قام عليه هذا المشروع عملياً، وقد ثبتت أهميته الحاسمة أثناء التطوير الفعلي وليس فقط نظرياً، كما سيرد بالتفصيل في الفصل السادس. تكمن الفكرة في أن نموذج الذكاء الاصطناعي، رغم عدم خضوعه لأي تدريب أو ضبط دقيق (Fine-tuning) خاص بهذا المنتج، يمكن "توجيهه" ضمن الاستعلام الواحد نفسه عبر إرفاق عدد صغير من الصور المرجعية الحقيقية الموسومة بوضوح (مثال: "هذه علبة سليمة"، "هذه علبة بها عيب في الجسم")، بحيث يستخدم النموذج قدرته العامة على المقارنة البصرية ليقيس مدى تشابه الصورة الجديدة المطلوب فحصها مع الأمثلة المرجعية المرفقة معها في نفس الاستعلام. الميزة الجوهرية لهذا الأسلوب أنه لا يتطلب أي إعادة تدريب أو بنية تحتية لتعلم الآلة؛ فتحسين أداء الكشف يتم ببساطة عبر استبدال أو إضافة ملف صورة واحد في مجلد محدد على القرص، لتنعكس آثاره فوراً في التحليل التالي دون أي تعديل في الشيفرة البرمجية.

2.5 خوارزميات تتبع الكائنات عبر الإطارات المتعاقبة

لضمان التقاط صورة واحدة نظيفة وواضحة لكل علبة فعلية أثناء مرورها أمام الكاميرا (وليس صوراً متكررة لنفس العلبة عبر عدة إطارات فيديو متعاقبة)، يعتمد النظام خوارزمية تتبع جشعة (Greedy Tracking Algorithm) تجمع بين مقياسين: المسافة الإقليدية بين مراكز الكتل المكتشفة (Centroid Distance) عبر الإطارات المتتالية، ونسبة التقاطع إلى الاتحاد بين المربعات المحيطة (Intersection over Union — IoU). يُبقي النظام على "مسار" (Track) مستقل لكل علبة فعلية طالما استمر رصدها بثبات نسبي عبر عدة إطارات متتالية، ولا تتحول العلبة إلى "مرشح التقاط" (Capture Candidate) مؤهل لإرسال صورتها للتحليل إلا بعد استيفاء شرطين: أن تكون قد رُصدت لعدد كافٍ من الإطارات المتتالية (لضمان استقرار موقعها وعدم كونها ضوضاء عابرة)، وأن يقع مركزها ضمن نطاق أفقي محدد مسبقاً من عرض الإطار يُسمى "منطقة الالتقاط" (Capture Zone)، وذلك لتفادي التقاط صور جزئية للعلب التي لا تزال داخلية إلى الإطار أو خارجة منه.

2.6 معالجة الصور في فضاء الألوان HSV

يعتمد الكشف الأولي عن العلب (قبل مرحلة التحليل بالذكاء الاصطناعي) على تقنيات معالجة صور تقليدية وليس على نموذج تعلم آلة، وذلك لأن مهمة "أين توجد علبة في الإطار؟" مهمة هندسية بسيطة نسبياً لا تستدعي تعقيد الاستعانة بنموذج ذكاء اصطناعي مكلف حسابياً وزمناً لكل إطار فيديو. يحوّل النظام كل إطار فيديو من فضاء الألوان الاعتيادي (BGR) إلى فضاء الألوان HSV (تدرج اللون، التشبع، القيمة)، وهو فضاء أكثر ملاءمة لفصل الأجسام البيضاء ذات التشبع اللوني المنخفض والقيمة الضوئية العالية عن السير الناقل الأزرق ذي التشبع اللوني المرتفع، عبر عتبات لونية (Thresholds) محددة مسبقاً. بعد عزل الكتل البيضاء المرشحة، يحدد النظام أولاً خط أعلى السير الناقل الأزرق (Belt Top Line) كنقطة مرجعية، ثم يسقط قواعد العلب المحتملة ضمن نطاق عمودي محدد حول هذا الخط، ويُخضع كل كتلة مرشحة لشروط هندسية إضافية (نسبة العرض إلى الارتفاع، الحد الأدنى للمساحة النسبية) لاستبعاد الضوضاء البصرية والتأكد من أن الكتلة المكتشفة تمثل فعلاً علبة وليست انعكاساً ضوئياً عابراً أو جسماً آخر.

منهجية ومراحل بناء المشروع

اثبتت في تطوير هذا المشروع منهجية تطوير تكرارية (Iterative Development) تقوم على بناء الأنبوب التقني (Pipeline) الأساسي أولاً بأدنى وظائفه، ثم تحسين كل مرحلة على حدة بناءً على الملاحظة الفعلية لأدائها على بيانات حقيقية، وهي منهجية أثبتت فعاليتها بشكل خاص في ضبط سلوك نموذج الذكاء الاصطناعي كما سيتضح في الفصل السادس. فيما يلي وصف تفصيلي لكل مرحلة من مراحل البناء بالترتيب الذي اتبعه فعلياً.

3.1 مرحلة التخطيط وتحديد المتطلبات

انطلق المشروع من تحديد واضح لطبيعة خط الإنتاج المستهدف: سير ناقل أزرق تمر عليه عبوات بلاستيكية بيضاء واسعة الفوهة بدون أغطية، مع الحاجة لالتقاط صورة كل عبوة وتحليلها آلياً وإصدار تقرير قابل للمراجعة البشرية. تحدد على أساس ذلك متطلبان رئيسيان يوجهان كل قرار تقني لاحق: أولاً، ضرورة أن يعمل النظام في الزمن الحقيقي أو قريباً منه دون أن يؤدي انتظار استجابة الذكاء الاصطناعي إلى تعطيل قراءة الإطارات التالية من الفيديو؛ وثانياً، ضرورة أن يستمر النظام في العمل دون توقف حتى في حال فشل تحليل عبوة واحدة لأي سبب تقني (خطأ شبكة، خطأ في واجهة برمجة التطبيقات، صورة غير واضحة)، بحيث لا يتسبب خطأ معزول في إيقاف كامل عملية الفحص على السير الناقل.

3.2 مرحلة تطوير وحدة الكشف عن العلب

بُنيت أولاً وحدة الكشف الأولي (BottleDetector) المعتمدة على معالجة الصور التقليدية الموصوفة في الفصل الثاني، وجرى ضبط العتبات اللونية والهندسية تكرارياً بالتجربة المباشرة على مقطع فيديو اختباري حقيقي حتى استقر أداء الكشف على تمييز العلب بثبات

دون أن يلتقط ضوؤاء بصرية عابرة أو انعكاسات ضوئية من السير الناقل نفسه كأجسام مرشحة.

3.3 مرحلة تطوير وحدة التتبع

بُنيت بعد ذلك وحدة التتبع (BottleTracker) الموصوفة في الفصل الثاني، بهدف تحويل سلسلة الكتل المكتشفة في كل إطار منفرد إلى مسارات (Tracks) مستقرة لكل علبة فعلية عبر الزمن، مع تحديد اللحظة المثلى لالتقاط الصورة النهائية لكل علبة — وهي اللحظة التي تكون فيها العلبة مرئية بالكامل ومستقرة الموضع ضمن منطقة الالتقاط المحددة، وليست في طور الدخول أو الخروج من إطار الكاميرا.

3.4 مرحلة دمج الذكاء الاصطناعي التوليدي

مُثلّت هذه المرحلة نقطة التحول الجوهرية في المشروع، حيث استُبدلت فكرة بناء نموذج تصنيف مخصص مدّرب من الصفر بفكرة استدعاء نموذج Claude Sonnet 5 المتاح عبر واجهة برمجة تطبيقات Anthropic لكل صورة علبة ملتقطة على حدة. تُفدّ هذا الاستدعاء عبر مجمّع خيوط تنفيذ (ThreadPoolExecutor) بعامل واحد يعمل بشكل غير متزامن (Asynchronous) بالتوازي مع حلقة قراءة الفيديو الرئيسية، بحيث لا تنتظر قراءة الإطار التالي اكتمال تحليل العلبة السابقة، وتُجمّع النتائج الجاهزة في كل دورة من دورات الحلقة الرئيسية دون حجب (Non-blocking Collection)، مع انتظار نهائي لأي تحليلات لا تزال معلقة عند انتهاء تشغيل النظام أو إيقافه يدوياً، ضماناً لعدم فقدان أي نتيجة تحليل.

3.5 مرحلة التحقق وتطبيع المخرجات

نظراً لأن استجابة نموذج الذكاء الاصطناعي نص حر بصيغة JSON قد يحتوي أحياناً على قيم غير متوقعة (أنواع عيوب موصوفة بمرادفات مختلفة، قيم ثقة خارج النطاق المسموح)، بُنيت طبقة تحقق وتطبيع صارمة باستخدام مكتبة Pydantic، تتولى تحويل أي مسمى عيب بديل أو مرادف (مثل "scratch" أو "stain" أو "molding") إلى أحد التصنيفات القياسية الثلاثة المعتمدة رسمياً في النظام، وثقيد قيمة الثقة الرقمية ضمن المجال المسموح به من صفر إلى واحد، وتضمن عدم قبول أي نص عربي فارغ في حقول الوصف أو الملخص.

3.6 مرحلة التصدير والتقارير

بعد اكتمال تحليل جميع العلب في تشغيل واحد، تُصدّر النتائج أولاً إلى ملف JSON منظم يتضمن إحصائيات إجمالية على مستوى التشغيل الكامل، ثم يُستدعى تلقائياً محرك تحويل يبني ملف تقرير Excel احترافي متعدد الأوراق (Sheets)، يتضمن صورة مصغرة فعلية لكل علبة مضمّنة داخل الجدول نفسه بجانب تحليلها النصي ومؤشرات الثقة الخاصة بها، وذلك بالاعتماد على مكتبة openpyxl ومكتبة Pillow لمعالجة الصور المصغرة.

3.7 مرحلة بناء الواجهة الرسومية

لتوسيع نطاق استخدام النظام ليشمل مشغلين غير تقنيين على أرض المصنع، طُوّرت واجهة رسومية كاملة باستخدام إطار عمل PySide6، توفر اكتشاف الكاميرات المتصلة تلقائياً، واختيار ملف فيديو بديل عبر مربع حوار تصفح ملفات، وشريط معاينة حي لمجرى الفيديو أثناء التشغيل، وأزرار تشغيل وإيقاف واضحة، مع تشغيل عملية الفحص بالكامل في خيط تنفيذ منفصل (QThread) حتى لا تتجمد الواجهة الرسومية أثناء المعالجة.

3.8 مرحلة التغليف والتوزيع

أخيراً، جرى تغليف الواجهة الرسومية بالكامل كملف تنفيذي مستقل لنظام تشغيل Windows باستخدام أداة PyInstaller، بحيث يمكن تسليم مجلد التوزيع النهائي لمشغل ميداني على جهاز لا يتوفر عليه بيئة بايثون مثبتة مسبقاً، مع نسخ ملف الإعدادات ومجلد الصور المرجعية للذكاء الاصطناعي تلقائياً بجانب الملف التنفيذي.

المعمارية التفصيلية للنظام

يتبنى النظام معمارية أنبوبية (Pipeline Architecture) مكوّنة من ست مراحل متعاقبة، تُنسّق جميعها عبر دالة تنسيق مركزية واحدة تستدعيها كل من واجهة سطر الأوامر والواجهة الرسومية على حد سواء، بما يضمن اتساق سلوك النظام بغض النظر عن واجهة الاستخدام المُشغّلة له.

1 مصدر الإطارات (Frame Source): يفتح مصدر الفيديو، سواء كان فهرس كاميرا فعلية (باستخدام واجهة برمجية خاصة بنظام التشغيل، مثل DirectShow على ويندوز أو V4L2 على لينكس) أو مساراً لملف فيديو مسجل، ويُنتج تدفقاً متعاقباً من الإطارات الخام.

2 الكشف (Detection): يعالج كل إطار عبر عتبات لونية في فضاء HSV لتحديد الكتل البيضاء المرشحة لتكون علبة، بعد تحديد موقع السير الناقل كنقطة مرجعية هندسية.

3 التتبع (Tracking): يربط الكتل المكتشفة عبر الإطارات المتعاقبة بخوارزمية مطابقة جشعة تجمع بين المسافة الإقليدية ونسبة التقاطع إلى الاتحاد، وتحدد اللحظة المثلى لالتقاط صورة كل علبة.

4 التحليل غير المتزامن بالذكاء الاصطناعي (Async AI Analysis): يرسل كل صورة ملتقطة إلى نموذج Claude Sonnet 5 عبر مجعّع خيوط تنفيذ منفصل، مرفقة بصور مرجعية توضيحية (كما يفصّل الفصل الخامس)، دون حجب حلقة قراءة الفيديو الرئيسية.

5 التحقق والتطبيع (Validation/Normalization): يتحقق من بنية استجابة النموذج ويطبّع أي مسميات عيوب بديلة إلى التصنيفات الرسمية الثلاثة، ويملأ التسميات العربية الثابتة محلياً دون طلبها من النموذج توفيراً للرموز اللغوية.

الإخراج (Output): يكتب النتائج المرتبة بحسب تسلسل الالتقاط إلى ملف JSON يتضمن إحصائيات التشغيل الكاملة، ثم يُولد تلقائياً تقرير Excel متعدد الأوراق مع الصور المضغوطة.

4.1 وحدة مصدر الفيديو

تتولى هذه الوحدة عزل تفاصيل التعامل مع عتاد الكاميرا الخاص بكل نظام تشغيل عن بقية أجزاء النظام، وتتضمن آلية اكتشاف تلقائي للكاميرات المتصلة بالجهاز عبر فحص مسارات الأجهزة المتاحة في نظام التشغيل، وهو ما يُستخدم لملء قائمة الكاميرات المتاحة في الواجهة الرسومية.

4.2 وحدة الكشف

تحدد هذه الوحدة أولاً خط أعلى السير الناقل عبر تحليل توزيع اللون الأزرق أفقياً عبر صفوف الإطار، ثم تسقط قواعد اللعب المرشحة ضمن نطاق عمودي محدد حول هذا الخط، وتُخضع كل كتلة مرشحة لشرطي نسبة العرض إلى الارتفاع والحد الأدنى للمساحة النسبية من مساحة الإطار الكلية، لضمان استبعاد أي كتلة لا تحمل الخصائص الهندسية المتوقعة لعلبة حقيقية.

4.3 وحدة التتبع

تُبقي هذه الوحدة سجلاً لكل "مسار" (Track) نشط، وتحديث موضع كل مسار بتنعيم تدريجي (Smoothing) للمربع المحيط بين الإطارات المتعاقبة لتفادي الاهتزاز البصري، ولا تعتبر أي علبة "مرشح التقاط" مؤهلاً لإرسال صورته للتحليل إلا بعد استقرار رصدها لعدد كافٍ من الإطارات ووقوع مركزها ضمن منطقة الالتقاط الأفقية المحددة، مع هامش أمان من حواف الإطار لضمان اكتمال العلبة في الصورة الملتقطة.

4.4 وحدة التحليل الذكي غير المتزامن

تُعرّف هذه الوحدة بروتوكولاً موحداً للمحلل (Analyzer Protocol) يسمح بتبديل محرك التحليل بسهولة بين محلل الذكاء الاصطناعي الفعلي ومحلل وهمي (No-AI Analyzer) يُستخدم لأغراض الاختبار السريع دون استهلاك أي استدعاءات فعلية لمواجهة برمجة التطبيقات. يلتقط المحلل الفعلي أي استثناء ناتج عن فشل الاستدعاء (خطأ شبكة، خطأ في معاملات الطلب، استجابة غير صالحة) ويحوّله إلى نتيجة "تعذر التحليل" بدلاً من إيقاف تشغيل النظام بالكامل، مع تسجيل رسالة الخطأ الفعلية ضمن حقل الوصف لأغراض التشخيص اللاحق.

4.5 وحدة النماذج والتحقق

تعتمد هذه الوحدة على مكتبة Pydantic لتعريف نماذج بيانات صارمة (Strict Data Models) تفرض قواعد تحقق تلقائية على كل حقل بيانات، وتتضمن حقولاً محسوبة (Computed Fields) تُشتق تلقائياً من قيمة الثقة الأساسية، مثل نسب الدقة والضبط والاسترجاع الخاصة بكل علبة على حدة، إضافة إلى دالة حساب إحصائيات إجمالية على مستوى التشغيل الكامل.

4.6 وحدة التصدير

تُبنى ملفات الإخراج عبر وحدتين متكاملتين: وحدة أولى تكتب ملف JSON المرتب زمنياً مع إحصائيات التشغيل، ووحدة ثانية تحوّل هذا الملف إلى تقرير Excel احترافي بثلاث أوراق عمل متكاملة (تقرير عربي شامل، ملخص إنجليزي، تفاصيل العلب)، مع تضمين صورة مصغرة فعلية لكل علبة داخل الجدول نفسه، وقدرة على حل مسار صورة العلبة سواء كان مساراً مطلقاً أو نسبياً.

آلية عمل الذكاء الاصطناعي وتصنيف العيوب

5.1 التصنيفات الثلاثة المعتمدة للعيوب

يعتمد النظام حالياً ثلاثة تصنيفات رسمية للعيوب، جرى تحديدها واستقرارها تدريجياً أثناء التطوير الفعلي بناءً على طبيعة العيوب الحقيقية الملاحظة على خط الإنتاج المدروس، وليس بشكل نظري مسبق:

التصنيف	الوصف	مستوى الشدة
body_defect عيب في جسم العلبة	انبعاثات، خدوش عميقة، تشققات، ثقوب حقيقية، أو تشوه في حلقة فوهة العلبة نفسها (عدم استدارة منتظمة)	متوسطة ومحدودة النطاق البصري
dirty علبة متسخة	بقع طين أو تراب أو اتساخ ذات لون دافئ (بي/أصفر) تختلف عن الظلال الضوئية الباردة، وتُرصَد مهما صغر حجمها	متغيرة الحجم، من بقعة صغيرة جداً إلى تلطخ كبير
factory_defect عيب تصنيعي جسيم	تشوه بنيوي كبير وبارز وواضح يهيمن على شكل العلبة عند أول نظرة، كوجود كتلة بلاستيكية زائدة كبيرة، كأن عملية التشكيل بالقالب نفسها فشلت	كبيرة وجسيمة وغير قابلة للتلباس



body_defect — انبعاج في
الجسم



علبة سليمة (لا عيوب)



dirty — بقعة اتساخ واضحة



body_defect — تشوه في
الفوهة



factory_defect — تشوه
بنيوي كبير

5.2 هندسة الأوامر النصية (Prompt Engineering)

ضمم أمر النظام (System Prompt) الموجّه للنموذج بعناية فائقة ليحدد هوية النموذج بوضوح كخبير فحص جودة متخصص، ويشرح كل تصنيف من التصنيفات الثلاثة بلغة دقيقة تميّزه عن التصنيفات الأخرى، ويضع قواعد صريحة لمنع النموذج من اختلاق عيوب غير موجودة فعلياً في الصورة، مع التأكيد المتكرر على ضرورة استخدام مصطلحات عربية دقيقة (مثل التمييز بين "تشوه" و"ثقب") تعكس طبيعة العيب الفعلية بدقة بدلاً من مصطلحات عامة قد تُضلل قارئ التقرير النهائي. أما أمر المستخدم (User Prompt) فيحدد بدقة متناهية بنية استجابة JSON المطلوبة، ويطلب صراحة الاختصار على أقصر وصف عربي ممكن، بهدف تقليل عدد الرموز اللغوية المُستهلكة في المخرجات دون التضحية بوضوح المعلومة.

5.3 أسلوب التعلم بالأمثلة المرجعية

يمثل هذا الأسلوب الابتكار التقني المحوري في المشروع: بدلاً من الاكتفاء بوصف نصي للعيوب المطلوب رصدها، يرفق النظام مع كل استدعاء فعلي مجموعة صور مرجعية حقيقية موسومة بوضوح (علبة سليمة، علبة بها انبعاج جسدي، علبة بها تشوه في الفوهة، علب متسخة بدرجات مختلفة من الوضوح، علبة بها عيب تصنيعي جسيم)، بحيث "يرى" النموذج مثلاً بصرياً حقيقياً وواضحاً لكل تصنيف قبل أن يُطلب منه تحليل الصورة الجديدة. تُقرأ هذه الصور المرجعية من مجلد مخصص على القرص عند بدء كل جلسة تحليل، وتُبنى محتوياتها مرة واحدة فقط ثم تُعاد بلا تغيير مع كل استدعاء تحليل لاحق، بما يوازن بين دقة الكشف وكفاءة الأداء. الميزة العملية الكبرى لهذا الأسلوب أن تحسين دقة الكشف مستقبلاً لا يتطلب أي تعديل في الشيفرة البرمجية إطلاقاً، بل يكفي استبدال أو إضافة صورة مرجعية أوضح في المجلد المخصص، لتنعكس آثارها فوراً في التحليل التالي — وهي بالضبط الآلية العملية التي استُخدمت لحل مشكلة عدم اتساق الكشف الموثقة في الفصل السادس.

5.4 التمييز بين البقع الحقيقية والظلال الضوئية

من أكثر التحديات دقة في تصنيف الاتساخ (dirty) هو تمييز بقعة اتساخ حقيقية عن ظل ضوئي طبيعي ناتج عن اتجاه الإضاءة أو انحناء سطح العلبة، إذ يمكن لظل خفيف أن يشبه بصرياً بقعة اتساخ باهتة. عالج هذا المشروع هذه الإشكالية عبر توجيه صريح ضمن أمر النظام يحدد معايير تمييز واضحة: البقعة الحقيقية تحمل عادة لوناً دافئاً (بني أو أصفر أو تان) يختلف بوضوح عن اللون الأبيض أو الرمادي للبلاستيك الأصلي، وتمتلك حافة حادة وغير منتظمة لا تتبع انحناء سطح العلبة، بينما الظل الضوئي يحمل لوناً بارداً (رمادي أو مائل للأزرق) بحافة ناعمة تدريجية تتبع انحناء السطح أو اتجاه مصدر الإضاءة. تُوجّه تعليمات صريحة أيضاً لفحص كامل سطح العلبة بعناية، بما في ذلك منطقة الكتف والرقبة وشريط القاعدة السفلي، لأن بقع الاتساخ الصغيرة جداً في هذه المناطق سهولة الإغفال بصرياً.

5.5 مقاييس الثقة كبديل عن الدقة والاسترجاع الحقيقيين

ملاحظة منهجية جوهرية

تُعرض في تقارير النظام (سواء ملف JSON أو تقرير Excel) ثلاثة مؤشرات رقمية تحمل تسميات "الدقة" (Accuracy)، و"الضبط" (Precision)، و"الاسترجاع" (Recall)، وهي تسميات مستعارة من أدبيات تقييم نماذج التصنيف في تعلم الآلة. غير أنه من الضروري التأكيد بوضوح تام على أن هذه المؤشرات في هذا النظام **ليست مقاييس إحصائية حقيقية بالمعنى الكلاسيكي**، وذلك لغياب أي خطوة فحص بشري مرجعي مستقل (Ground Truth) تُقارَن بها نتائج النموذج. بل إن هذه المؤشرات جميعها مُشتقة حصراً من درجة الثقة الذاتية التي يُرفقها النموذج مع كل قرار (رقم بين صفر وواحد يعبر عن مدى ثقة النموذج بقراره النهائي بخصوص العلبة).

فعلى مستوى العلبة الواحدة: تمثل "الدقة" ثقة النموذج بقراره العام أياً كان (سليمة أو معيبة)، وتظهر "الضبط" فقط حين تُرصد العلبة معيبة (وتساوي ثقة النموذج بالعيب المرصود)، بينما يظهر "الاسترجاع" فقط حين تكون العلبة سليمة (الحكم وتساوي ثقة النموذج بأن لا شيء قد فاته). أما على مستوى التشغيل الكامل، فتُحسب هذه القيم كمتوسطات: الدقة كمتوسط الثقة على كل اللعب، والضبط كمتوسط الثقة على اللعب المعيبة فقط، والاسترجاع كمتوسط الثقة على اللعب السليمة فقط. إذا كانت هناك حاجة مستقبلية لحساب مقاييس دقة واسترجاع

إحصائية حقيقية، فإن ذلك يتطلب بالضرورة إضافة خطوة فحص يدوي مستقل يُقارن بها قرار النموذج، ولا توجد طريقة لاشتقاق هذه المقاييس الحقيقية من ثقة النموذج الذاتية وحدها مهما بلغت دقة صياغة الأمر النصي.

التحديات التقنية الفعلية وحلولها

يوثق هذا الفصل بأمانة علمية كاملة عدداً من التحديات التقنية الحقيقية التي واجهت تطوير النظام أثناء الاستخدام الفعلي، مع شرح تفصيلي لعملية التشخيص والحل المتبعة في كل حالة، باعتبار أن هذا التوثيق يمثل جزءاً أصيلاً من المساهمة المنهجية للمشروع، إذ يبرهن عملياً على كيفية التعامل مع أوجه القصور غير المتوقعة في أنظمة الرؤية الحاسوبية القائمة على النماذج التوليدية.

6.1 مشكلة عدم اتساق الكشف عن العيوب المتكررة

لوحظ أثناء تشغيل النظام على مقطع فيديو اختباري حقيقي أن عدة علب تحمل نفس نوع العيب البصري تقريباً (انبعاج بيزاوي في نفس المنطقة تقريباً من الجسم) لم تُصنّف جميعها بشكل متسق؛ فبعضها صُنّف بشكل صحيح كمعيب، بينما صُنّف بعضها الآخر خطأً كسليم رغم تشابه المظهر البصري الظاهري. جرى فحص هذه الحالة بعناية عبر معاينة الصور المعنية فعلياً ومقارنتها ببعضها بعضاً، وتبيّن أن الاعتماد على وصف نصي وحده للعيوب المطلوب رصده (دون أي مرجع بصري مرافق) لم يكن كافياً لضمان اتساق القرار عبر حالات متشابهة. كان الحل المعتمد هو تطبيق أسلوب التعلم بالأمثلة المرجعية الموصوف في الفصل الخامس: إرفاق صور حقيقية مؤكدة لهذا النوع بعينه من الانبعاج ضمن كل استدعاء تحليل لاحق، وقد أثبتت الاختبارات الفعلية بعد هذا التعديل اكتشاف جميع الحالات المتشابهة بثبات ودون استثناء.

6.2 مشكلة معامل الحرارة الموهجور في النموذج

ظهرت حالة عطل غير متوقعة تمثلت في تصنيف علبة سليمة تماماً كمعيبة، مع ظهور نص وصف غريب يحتوي على رسالة خطأ تقنية بدلاً من وصف عيب حقيقي. تتبع هذا العطل

بعناية إلى مصدره الجذري، فتبين أن استدعاء واجهة برمجة التطبيقات كان يتضمن معامل "درجة الحرارة" (Temperature Parameter) الذي أصبح غير مدعوم إطلاقاً من قبل إصدار النموذج المستخدم، مما كان يتسبب في فشل كل استدعاء بخطأ من نوع "طلب غير صالح" قبل أن تصل الصورة أصلاً إلى النموذج للتحليل، بينما كانت آلية معالجة الأخطاء المصممة أصلاً لإبقاء التشغيل مستمراً (كما ورد في الفصل الرابع) تلتقط هذا الفشل التقني وتحوله إلى نتيجة "تعذر التحليل" مصحوبة برسالة الخطأ الفعلية ضمن حقل الوصف، مما أدى ظاهرياً إلى نتيجة مضللة توهي بوجود عيب حقيقي. جرى حل المشكلة عبر حذف هذا المعامل بالكامل من الاستدعاء، مع رفع الحد الأقصى المسموح به لعدد الرموز اللغوية في الاستجابة، وتحسين صياغة الأمر النصي بشكل عام في نفس الوقت.

6.3 مشكلة التمييز بين الاتساخ والظل الضوئي

عند اختبار النظام على صور حقيقية لعلب متسخة بدرجات متفاوتة من الوضوح، لوحظ أن إحدى الصور ذات البقعة الخفيفة جداً صُنِّفت خطأ كـ "عيب في الجسم" (انبعاث) بدلاً من "علبة متسخة"، بسبب تشابه شكل البقعة الخفيفة مع مظهر انبعاث بصري طفيف في ظل إضاءة معينة. عولجت هذه الحالة عبر إضافة معايير تمييز صريحة ضمن الأمر النصي، تعتمد أساساً على درجة اللون (الاتساخ دافئ اللون، الظل بارد اللون) وشكل الحافة، كما وثِّقه الفصل الخامس بالتفصيل. وقد لوحظ أن جودة الإضاءة أثناء التصوير تبقى عاملاً حاسماً في وضوح هذا التمييز، وهو ما يفتح مجالاً للتحسين المستقبلي المذكور في الفصل العاشر.

6.4 مشكلة إضافة تصنيف العيب التصنيعي دون تعارض مع العيوب

الجسدية

عند إضافة التصنيف الثالث "عيب تصنيعي" (factory_defect) إلى جانب التصنيفين السابقين، كان هناك احتمال حقيقي أن يتسبب وجود تصنيف جديد أكثر شدة في "سحب" حالات كانت تُصنَّف سابقاً بشكل صحيح ضمن "عيب في الجسم" نحو التصنيف الجديد خطأً، خصوصاً في الحالات التي يكون فيها التشوه واضحاً نسبياً. لتفادي هذا الخطر، وُضع معيار فصل صريح قائم على الحجم النسبي وهيمنة العيب على المظهر العام للعلبة (عيب جسيم يهيمن على الشكل عند أول نظرة مقابل عيب محدود النطاق)، وأُجري اختبار تحقق فعلي بعد التعديل

للتأكد من أن الحالات التي كانت تُصنّف سابقاً بشكل صحيح ضمن "عيب في الجسم" ظلت مصنّفة بنفس الشكل الصحيح رغم إضافة المنافس الجديد، وقد أكدت نتائج الاختبار سلامة الفصل بين التصنيفين.

6.5 تقليل استهلاك الرموز اللغوية في المخرجات

لضمان كفاءة اقتصادية أعلى في استخدام واجهة برمجة التطبيقات، أُعيدت هندسة بنية استجابة JSON المطلوبة من النموذج لتشمل فقط الحقول الجوهرية غير القابلة للاشتقاق محلياً (نوع العيب، وصف مختصر جداً، ملخص عام، درجة ثقة رقمية واحدة)، بينما تُشتق التسمية العربية الثابتة لكل نوع عيب محلياً من جدول ترميز داخلي في النظام دون طلبها من النموذج إطلاقاً، وذلك لأنها قيمة ثابتة معروفة مسبقاً لا حاجة لتوليدها في كل استدعاء.

واجهات الاستخدام

7.1 واجهة سطر الأوامر

توفر واجهة سطر الأوامر (Command-Line Interface) وسيلة تشغيل مرنة موجهة للاستخدام التقني والاختبار، وتدعم مجموعة واسعة من خيارات الضبط القابلة للتمرير عند التشغيل، منها تحديد مصدر الفيديو (فهرس كاميرا أو مسار ملف)، ومسار ملف الإخراج النهائي، ومجلد حفظ الصور المقصودة، ونموذج الذكاء الاصطناعي المستخدم، وحد أقصى لعدد العلب المراد تحليلها في تشغيل تجريبي، وخيار تعطيل استدعاء الذكاء الاصطناعي بالكامل لأغراض الاختبار السريع لبقية مراحل الأنابيب دون تكلفة استدعاءات فعلية.

7.2 الواجهة الرسومية

صُممت الواجهة الرسومية باستخدام إطار عمل PySide6 لتكون سهلة الاستخدام لمشغل غير تقني على أرض المصنع، وتتضمن عناصر تحكم واضحة لاختيار مصدر التشغيل (كاميرا مكتشفة تلقائياً أو ملف فيديو يُختار عبر متصفح ملفات)، وتحديد عدد أقصى للعلب المراد فحصها أو اختيار تشغيل مفتوح دون حد حتى يتم إيقافه يدوياً، مع شريط معاينة حي يعرض الإطار الحالي للفيديو وحالة كل علبة مرصودة (قيد التتبع، قيد التحليل، سليمة، معيبة) بألوان مميزة، وأزرار مباشرة لفتح ملف تقرير Excel الناتج أو مجلد النتائج فور اكتمال التشغيل.

7.3 دعم الكاميرا وملفات الفيديو

تدعم كلتا الواجهتين مصدرين للتشغيل بشكل متكافئ تماماً من حيث المعالجة الداخلية: كاميرا حية متصلة بالجهاز (يُفتح الاتصال بها عبر واجهة برمجية خاصة بنظام التشغيل المستخدم)، أو ملف فيديو مسجل مسبقاً بأي صيغة شائعة (مثل MP4 أو AVI أو MOV أو

(MKV)، وهو ما يسمح باختبار النظام وتطويره دون الحاجة لتوفر كاميرا فعلية متصلة أثناء مرحلة التطوير، كما يسمح لاحقاً باستخدام تسجيلات فيديو حقيقية من خط الإنتاج لأغراض المراجعة أو إعادة التحليل.

النتائج والتقارير المصدرة

8.1 هيكلية ملف JSON

يتضمن ملف الإخراج الرئيسي مصدر التشغيل واسم النموذج المستخدم وتاريخ الإنشاء، إضافة إلى كتلة إحصائيات إجمالية على مستوى التشغيل الكامل (عدد العلب الكلي، عدد العلب المعيبة والسليمة، ومتوسطات مؤشرات الثقة الثلاثة الموضحة في الفصل الخامس)، ثم قائمة مرتبة زمنياً بجميع العلب المفحوصة، تتضمن لكل علبة رقمها التسلسلي ورقم الإطار وزمن ظهورها في الفيديو ومسار صورتها المقصودة، وقائمة العيوب المكتشفة (إن وُجدت) بنوعها ووصفها العربي المختصر وتسميتها الثابتة، إضافة إلى الملخص العام العربي ودرجة الثقة ومؤشرات الدقة والضبط والاسترجاع الخاصة بتلك العلبة تحديداً.

8.2 تقرير Excel

يتضمن تقرير Excel الناتج ثلاث أوراق عمل متكاملة: ورقة "التقرير" الرئيسية التي تجمع ملخصاً إحصائياً عربياً شاملاً في الأعلى وجدول تفاصيل كامل لكل علبة أسفله، وورقة "الملخص" الإنجليزية المختصرة للمراجعة السريعة، وورقة "تفاصيل العلب" المخصصة بالكامل لعرض كل علبة على حدة. يتميز التقرير بتضمين صورة مصغرة فعلية لكل علبة داخل الجدول نفسه في العمود الأخير، محاذاة تماماً مع صف تلك العلبة وبارتفاع صف مناسب لعرضها بوضوح، بحيث يمكن للمراجع البشري رؤية الصورة الفعلية للعلبة وتحليلها النصي ومؤشرات الثقة الخاصة بها في نظرة واحدة متكاملة دون الحاجة للرجوع إلى مجلد الصور المقصودة بشكل منفصل.

8.3 أمثلة توضيحية حقيقية

توضح الصور الواردة في الفصل الخامس (القسم 5.1) أمثلة حقيقية فعلية من الصور المرجعية المعتمدة في النظام، وتعكس التنوع البصري الحقيقي بين التصنيفات الثلاثة للعيوب من حيث الحجم والموقع والخصائص اللونية، وهي نفس الصور التي يعتمدها النظام فعلياً كأمثلة توجيهية (Few-shot Examples) مرفقة مع كل استدعاء تحليل حقيقي، وليست صوراً توضيحية منفصلة عن آلية عمل النظام الفعلية.

مميزات النظام من الألف إلى الياء

يستعرض هذا الفصل أبرز مميزات النظام مرتبة بشكل موضوعي شامل يغطي الجوانب التقنية والوظيفية والتشغيلية كافة.

1 كشف آلي كامل للعلب

دون أي تدخل بشري في مرحلة الرصد الأولي، بالاعتماد على معالجة صور تقليدية سريعة وخفيفة حسابياً.

2 تتبع ذكي يمنع التكرار

التقاط صورة واحدة فقط ونظيفة لكل علبة فعلية عبر خوارزمية تتبع تجمع المسافة والتقاطع الهندسي.

3 تحليل غير متزامن

استدعاء الذكاء الاصطناعي لا يعطل قراءة الفيديو الحية بفضل المعالجة المتوازية بخيوط تنفيذ منفصلة.

4 مقاومة للأعطال

فشل تحليل علبة واحدة لا يوقف تشغيل النظام بالكامل، بل يُسجّل كنتيجة خاصة ويستمر الفحص.

5 تعلم بالأمثلة دون تدريب

تحسين دقة الكشف عبر إضافة صور مرجعية جديدة فقط، دون أي تعديل برمجي أو إعادة تدريب.

6 ثلاثة تصنيفات دقيقة للعيوب

عيب جسدي، اتساخ، وعيب تصنيعي جسيم، بحدود فصل واضحة بين كل تصنيف والآخر.

7 تمييز الاتساخ عن الظل

معايير مريحة قائمة على درجة اللون وشكل الحافة لمنع الالتباس بين البقعة الحقيقية والظل الضوئي.

8 حساسية للتفاصيل الدقيقة

القدرة على رصد بقع اتساخ صغيرة جداً حتى بحجم نقطة واحدة في مناطق يسهل إغفالها كالكتف والقاعدة.

9 تقليل استهلاك الرموز اللغوية

بنية استجابة مضغوطة ومحسوبة بعناية
لخفض كلفة كل استدعاء دون فقدان جودة التحليل.

10 مؤشرات ثقة شفافة

مؤشرات دقة وضبط واسترجاع موثقة بوضوح
كمشتقات من ثقة النموذج، دون أي ادعاء إحصائي مضلل.

11 تقارير Excel احترافية

ثلاث أوراق عمل متكاملة مع صور مصغرة
حقيقية مضمنة في الجدول نفسه بجانب كل تحليل.

12 دعم اللغة العربية بالكامل

كل الأوصاف والملخصات والتسميات موجهة
للقارئ العربي، مع محاذاة يمين-ليسار كاملة في التقارير.

13 واجهتا استخدام مزدوجتان

سطر أوامر للاستخدام التقني، وواجهة رسومية بسيطة للمشغل الميداني غير التقني.

14 دعم كاميرا حية أو ملف فيديو

مرونة كاملة في اختيار مصدر التشغيل دون أي فرق في جودة أو آلية المعالجة الداخلية.

15 معاينة حية للحالة

عرض مباشر لحالة كل علبة مرصودة (قيد التتبع، قيد التحليل، سليمة، معيبة) بألوان مميزة أثناء التشغيل.

16 تغليف وتوزيع مستقل

حزمة تنفيذية كاملة لنظام ويندوز لا تتطلب تثبيت بايثون على جهاز المشغل النهائي.

17 إيقاف تعاوني آمن

آلية إيقاف تنتظر اكتمال أي تحليلات معلقة قبل كتابة النتائج النهائية، لضمان عدم فقدان أي بيانات.

18 قابلية توسع مرنة

إضافة تصنيف عيب جديد أو تعديل تعريف تصنيف قائم لا يتطلب إعادة هيكلة معمارية للنظام.

19 توثيق تقني داخلي شامل

توثيق مرجعي كامل لقرارات التصميم وأسباب كل تعديل رئيسي، لتسهيل الصيانة المستقبلية.

20 منهجية تطوير تكرارية موثقة

كل تحسين جوهري في دقة الكشف تم بناءً على ملاحظة فعلية واختبار حقيقي وليس افتراضاً نظرياً.

حدود النظام والتوصيات المستقبلية

10.1 الحدود الحالية

- غياب خطوة فحص بشري مرجعي مستقل يجعل مؤشرات الدقة والضبط والاسترجاع الحالية مؤشرات ثقة تقريبية وليست مقاييس إحصائية دقيقة بالمعنى الكلاسيكي.
- حساسية أداء تصنيف الاتساخ لجودة الإضاءة أثناء التصوير، حيث قد تتشابه بقعة اتساخ خفيفة جداً مع ظل ضوئي في ظروف إضاءة غير مثالية.
- اعتماد الكشف الأولي عن العلب على عتبات لونية مضبوطة يدوياً لمنتج ولون سير ناقل بعينهما، مما يتطلب إعادة معايرة عند تغيير نوع العبوة أو لون السير الناقل.
- اعتماد جودة تصنيف كل نوع عيب جديد بشكل مباشر على جودة ووضوح الصور المرجعية المتاحة لذلك النوع تحديداً.

10.2 التوصيات المستقبلية

- إضافة وحدة فحص بشري مرجعي اختيارية تسمح لمشغل مختص بتأكيد أو تصحيح قرار النظام يدوياً لعينة من العلب، لبناء مقاييس دقة واسترجاع إحصائية حقيقية بمرور الوقت.
- تحسين ظروف الإضاءة الفيزيائية عند نقطة الالتقاط على السير الناقل، بما يعزز تلقائياً من دقة التمييز بين بقع الاتساخ الحقيقية والظلال الضوئية.
- توسيع مكتبة الصور المرجعية تدريجياً لتغطية مزيد من الحالات الحديثة والصعبة لكل تصنيف عيب، خصوصاً الحالات الدقيقة الصعبة التمييز.
- دراسة إمكانية تعميم النظام على أنواع عبوات إضافية عبر إعادة معايرة عتبات الكشف اللونية وتزويده بمجموعات صور مرجعية مستقلة لكل نوع منتج جديد.

- دراسة جدوى دمج لوحة تحكم تحليلية (Dashboard) تعرض اتجاهات معدل العيوب عبر الزمن للمساعدة في اتخاذ قرارات صيانة استباقية لخط الإنتاج.

خلاصة الدراسة التطبيقية

قدّم هذا الفصل عرضاً تطبيقياً شاملاً ومفصلاً لمشروع نظام فحص جودة آلي حقيقي، يوظف تقنيات معالجة الصور التقليدية لمهمة الكشف الأولي عن العلب وتتبعها، ونموذج ذكاء اصطناعي توليدي متعدد الوسائط (Claude Sonnet 5) كمحرك تحليل بصري رئيسي، مدعوماً بأسلوب التعلم بالأمثلة المرجعية القليلة كبديل عملي فعال عن إعادة تدريب نموذج تصنيف مخصص من الصفر. أظهرت التجربة العملية الموثقة بالتفصيل في الفصل السادس أن هذا الأسلوب قابل للتطبيق الفعلي والتحسين التكراري المستمر، وأن معظم التحديات التي واجهت الفريق أثناء التطوير كانت قابلة للحل عبر تحسين الأمثلة المرجعية المرفقة والأوامر النصية الموجهة للنموذج، دون الحاجة لأي بنية تحتية معقدة لتعلم الآلة التقليدي.

وفي الوقت نفسه، حرص هذا الفصل على الإفصاح المنهجي الصريح عن حدود النظام الحالية، وعلى رأسها طبيعة مؤشرات الدقة والاسترجاع المعروضة كمؤشرات ثقة تقريبية وليست مقاييس إحصائية حقيقية، بما يعكس التزاماً بالأمانة العلمية في عرض النتائج، ويفتح في الوقت ذاته مساراً بحثياً واضحاً للعمل المستقبلي المتمثل في إضافة خطوة فحص بشري مرجعي تتيح قياساً إحصائياً دقيقاً وكاملاً لأداء النظام.

قائمة المصادر والمراجع التقنية

1. الوثائق الرسمية لمواجهة برمجة التطبيقات الخاصة بنماذج Claude، شركة Anthropic.
2. الوثائق الرسمية لمكتبة معالجة الصور مفتوحة المصدر OpenCV.
3. الوثائق الرسمية لمكتبة التحقق من البيانات Pydantic (الإصدار الثاني).
4. الوثائق الرسمية لمكتبة openpyxl لإنشاء ومعالجة ملفات Excel برمجياً.
5. الوثائق الرسمية لإطار عمل الواجهات الرسومية PySide6 (Qt for Python).
6. الوثائق الرسمية لأداة التغليف والتوزيع PyInstaller.
7. مراجع عامة في أدبيات الرؤية الحاسوبية التقليدية: تقنيات فضاء الألوان HSV، وخوارزميات كشف الحواف وعتبات الشدة اللونية.
8. مراجع عامة في أدبيات نماذج الرؤية اللغوية الكبيرة (Large Vision-Language Models) ومفهوم التعلم بالأمثلة القليلة (Few-shot / In-context Learning).

تم إعداد هذا الفصل التطبيقي بالاستناد المباشر إلى الشيفرة البرمجية الفعلية للمشروع وسجل تطويره التوثيقي الكامل.